

Universität
Basel



Bachelorarbeit

Schwache Markteffizienz bei Kryptowährungen

Wirtschaftswissenschaftliche Fakultät, Universität Basel

Autor

Jonas Mazacek, 19-054-196
Oberweier 128, 4458 Eptingen
j.mazacek@stud.unibas.ch

Betreuer

Dr. Jacqueline Henn
jacqueline.henn@unibas.ch

Einreichdatum

17.06.2022

Inhalt

1	Einleitung	4
1.1	Literatur	6
2	Methodologie.....	9
2.1	Daten	9
2.2	Statistische Tests zur Überprüfung der schwachen Markteffizienz.....	10
2.3	Trading-Strategien	13
3	Empirische Erkenntnisse	14
2.1	Deskriptive Statistik.....	14
2.2	Statistische Tests zur Überprüfung der schwachen Markteffizienz.....	17
2.2.1	Statische Untersuchungen.....	17
2.2.2	Dynamische Untersuchungen	19
2.3	Trading-Strategien	20
2.3.1	Chande Momentum Oscillator.....	21
2.3.2	David Varadi Indicator	22
3	Diskussion	23
3.1	Grenzen der Resultate und weitere mögliche akademische Arbeit	24
4	Schlussfolgerungen.....	27
	Appendix	28
A.1	Resultate fortlaufender AVR Test	28
A.2	Resultate fortlaufender Hurst Exponent	29
A.3	Resultate fortlaufender Runs Test	29
A.4	Resultate fortlaufender Ljung-Box Test	30
	Referenzen	31

Abbildungsverzeichnis

Abbildung 1 Die 10 wichtigsten Kryptowährungen	5
Abbildung 2 Deskriptive Statistik	15
Abbildung 3 AVR-, Hurst- und Runs-Test über gegebene Zeiträume	16
Abbildung 4: Ljung-Box Testresultate	18
Abbildung 5: Ljung-Box-Test bis 31.12.2018	18
Abbildung 6 Ljung-Box-Tests vom 1.1.2019 bis 24.04.2022	19
Abbildung 7 Vergleich der CMO-Trading Strategie und Buy-Hold Strategie.....	21
Abbildung 8 Vergleich der DVI-Trading Strategie und Buy-Hold Strategie.....	22

Abkürzungsverzeichnis

ANN	artificial neural networks
API	Aplication Programming Interface
ARCH	Autoregressive Conditional Heteroskedasticity
AVR	Automated Variance Ratio
BDS	Brock Dechert Scheinkman
BTC	Bitcoin
CMO	Chande Momentum Oscilator
DOGE	Dogecoin
DVI	David Varadi Indicator
ETH	Ethereum
LB	Ljung Box
LTC	Litecoin
SMH	schwache Markteffizienzhypothese
SR	Sharpe Ratio
STR	Sortino Ratio
XLM	Stellar
XMR	Monero
XRP	Ripple

1 Einleitung

Das Ziel dieser Arbeit ist es die schwache Markteffizienzhypothese bei diversen Kryptowährungen zu testen. In der Einleitung wird die Welt der Kryptowährungen und Markteffizienz beleuchtet. Im Anschluss werden Wege aufgezeigt mit welchen Mitteln, die Markteffizienz bei Kryptowährungen in der Akademie bereits getestet wird. Dabei werde ich gewisse standardisierte Tests anwenden, welche aus der Finance durch die Akademie für das Testen bei Kryptowährungen entnommen wurden. Zuletzt bediene ich mich bei den Trading-Strategien, um zu praktisch die Ergebnisse der Tests zu überprüfen. Das Ziel dieser Arbeit ist es Effekte zu untersuchen, die über längere Zeiträume bestehen. Somit wird pro Tag ein Preis verwendet, welcher zu einer gewissen Zeit regelmässig entnommen wurde.

Nakamoto veröffentlichte 2008 das Konzept von Bitcoin im Paper: «Bitcoin: A Peer-to-Peer Cash System». Das Konzept war revolutionär in dem Sinne das es nicht auf Vertrauen verliess. Mit Hilfe von digitalen Signaturen und einem peer-to-peer Netzwerk welche mithilfe einem proof-of-work Mechanismus einen öffentlichen Verlauf der Transaktionen erstellt, erübrigte sich eine zentrale Autorität, welche Transaktionen prozessieren würde (Nakamoto, 2008). Proof-of-work bedeutet das für Operationen im Netzwerk Opportunitätskosten aus der realen Welt, d.h. nicht in der Währung selbst, aufgewendet werden. In diesem Fall geht es um Strom in der Form von Rechenleistung (Böhme et al., 2015).

Darauffolgend entstanden weitere Kryptowährungen, mit anderen Eigenschaften. Die Auswahl für diese Arbeit wurde nicht anhand der Grösse getroffen, da die wichtigsten Kryptowährungen, gemessen an der Gesamtkapitalisierung, mit der Ausnahme von Bitcoin und Ethereum ständig am Wechseln sind. Dies ist an der Tabelle 1 ersichtlich. Das wichtigste Kriterium für die Auswahl, war eine Anwendung des Lindy-Effekts. Der besagt bei Konzepten, welche kein natürliches Alter haben mit steigendem Alter sich die Wahrscheinlichkeit für weiterbestehen dieser Konzepte erhöht (Taleb, 2012). Dies liesse sich, in Kombination mit einem gewissen Anspruch auf Wichtigkeit einer Kryptowährung wie folgt auf unser Problem anwenden:

Eine Kryptowährung wird in die Analyse miteinbezogen, falls sie sich, per Stichtag in der Vergangenheit und in der Gegenwart, zwischen den X. wichtigsten Kryptowährung befindet.

Abbildung 1

Die 10 wichtigsten Kryptowährungen im Verlauf der Zeit

Diese Tabelle zeigt die wichtigsten 10 Kryptowährungen gemessen an der Gesamtkapitalisierung, welche aufgrund des Preises und dem Gesamtangebot berechnet wurde.
(Quelle: <https://coinmarketcap.com>)

Position	Per 3. April 2016	Per 7. April 2019	Per 3. April 2022
1	Bitcoin	Bitcoin	Bitcoin
2	Ethereum	Ethereum	Ethereum
3	XRP	XRP	Tether
4	Litecoin	Bitcoin Cash	BNB
5	Dash	Litecoin	USD Coin
6	MaidSafeCoin	EOS	Solana
7	Dogecoin	Binance Coin	XRP
8	Hyperspace	Stellar	Cardano
9	Monero	Cardano	Terra
10	BitShares	Tether	Avalanche

Als Stichtage wurden der 3. April von 2016 und 2022 ausgewählt. Als Benchmark für Wichtigkeit die 50. wichtigsten. Somit erhalten wir 8 Kryptowährungen: Bitcoin, Ethereum, Ripple, Litecoin, Dogecoin, Monero, Stellar und Tether (coinmarketcap.com, 2022). Dabei ergibt es keinen Sinn Tether zu analysieren da dessen Preis an den Dollar der Vereinigten Staaten gebunden ist. Mithilfe dieser Auswahl werden implizit auch Phänomene wie Aktivität an der Weiterentwicklung einer Kryptowährung oder reale Verwendung miteinbezogen, ohne notwendigerweise diese Merkmale separat analysieren zu müssen.

Die Markteffizienzhypothese wurde durch Fama 1970 vorgestellt. Ein Markt ist vollständig effizient, wenn er alle öffentlich Verfügbaren Informationen reflektiert. Im Sinne von Fama ist ein Markt schwach effizient, wenn mit Preisen aus der Vergangenheit, keine Preise aus der Zukunft vorausgesagt werden können (Fama, 1970). Es sollte somit nicht möglich sein systematisch eine grössere Rendite als der Markt zu generieren. Die Renditen sollten somit einem Random-Walk entsprechen.

Die Thematik der schwachen Markteffizienzhypothese zu überprüfen ist interessant aus einem Wirtschaftstheoretischen Aspekt, da es sich um eine fundamentale Theorie handelt. Ausserdem ist dies aber auch aus der unternehmerischen Seite interessant, da eine

potenzielle Marktineffizienz, eine Geschäftsmöglichkeit ist. Das Testen der Trading-Strategien sollte dementsprechend aus beiden Aspekten betrachtet werden. Ausserdem ist das Ziel dieser Arbeit die möglichst fundamentalen Ineffizienzen zu analysieren. Abschliessend sollte auch vermerkt sein, dass es nicht Bestandteil dieser Arbeit ist die Verbundhypothese bei der Markteffizienz zu debattieren.

1.1 Literatur

Eine der ersten wissenschaftlichen Paper in der Thematik der Überprüfung der schwachen Markteffizienzhypothese bei Kryptowährungen veröffentlichte Uruquhart 2017. Er testete mithilfe von statistischen Tests, wie die Ljung-Box-, Runs-, Bartels-, AVR-, BDS- und R-S-Test die vorliegende Hypothese. Er kam zum Schluss das Bitcoin, die einzige von ihm getestete Kryptowährung, über die ganze Zeit gemessen ineffizient sei. Jedoch gab es bereits in seiner Arbeit Anzeichen, dass über die Zeit hinweg in diesem Markt Bitcoin effizienter würde. Dies zeigte sich dadurch dass die letzte der drei Zeitperioden, in der er das Zeitfenster unterteilte, schwach effizient war (Uruquhart, 2016). Diese Studie wurde durch Nadarajah und Chu (2017) repliziert. Sie verwendeten dabei gleiche Preise als Basis und die Mehrzahl der Tests war die gleiche. Der Unterschied bestand in der Transformation der Exponenten und der Unterteilung der Zeitperiode in 2 und nicht 3 Teile. Sie fanden das Bitcoin mehrheitlich effizient ist (Nadarajah and Chu, 2017).

Sehr nahe zu Uruquhart in der Methodologie steht, das Paper von Brauneis und Mestel (2018). Sie weiten die Anzahl statistischer Tests und Kryptowährungen auf 73 aus. Sie finden dabei, dass Bitcoin die effizienteste Währung ist und dass sich die Effizienz im Verlaufe der Zeit von ineffizient zu effizient wechselte. Auf der anderen Seite sind alle anderen Kryptowährungen sehr heterogen in ihrem Verhalten. Die Turnoverrate ist für sie ein sehr wichtiger Treiber in der Effizienz (Brauneis and Mestel, 2018).

Dies wurde durch diverses nachfolgendes Paper, wie das von Lopez-Martin et al bestätigt. Diese weiteten die Tests auf weitere einzelne Kryptowährungen aus und machten zusätzlich gebrauch von Benchmarks wie dem Hurst-Exponent oder Dominiquez-Lobato test. Sie unterteilten die Zeitreihe in 4 Teile und fanden das Bitcoin (die grösste Kryptowährung) über die Zeit effizienter wird. Trotzdem war sie auch wie bei Uruquhart (2017) nicht über die gesamte Zeit Markteffizient. Die anderen Kryptowährungen verhielten sich ähnlich. Sie wiesen dies als Evidenz für adaptive Märkte (López-Martín et al., 2021).

Im Unterschied zu den vorigen Papers verwendete Aggarwal (2019) Tests mit der Anwendung der ARCH-Modelle. ARCH-Modelle unterstellen das die bedingte Varianz der Modellfehler abhängig sind vom realisierten Zufallsfehler der Vorperiode. Er unterteilt dabei das Zeitfenster nicht und stellt fest, wie Uruquhart (2017), das über das ganze Zeitfenster hinweg Bitcoin ineffizient ist (Aggarwal, 2019). Einen weiteren nicht standardisierten Weg, geht Tran und Leirvik (2019). Sie messen dabei die Adjustierte Marktineffizienz Magnitude (AMIM). Der Vorteil dieser Methode ist, dass wir ein stetiges Mass in jedem Zeitpunkt für das Ausmass der Ineffizienz haben. Es zeigt sich wie in dem vorhergehenden Paper das Bitcoin nach einer Anfangsphase der Ineffizienz effizient geworden ist. Das heterogene Bild bei anderen Kryptowährungen mit einer steigenden Effizienz über die Zeit hinweg wiederholt sich auch (Tran and Leirvik, 2020).

Noch vor Uruquhart veröffentlicht Kristoufek (2015) ein Paper wo er eine Wavelet Kohärenzanalyse verwendet und die externen und internen Treiber des Bitcoinpreises untersucht. In der langen Frist machen makroökonomische Grössen den grössten Einfluss aus, in der kurzen Frist sind es jährliche Zyklen (Kristoufek, 2015). In seiner Tradition steht Fidrmuc et al. (2019) durch Anwendung der gleichen Methode auf die SMH. Dabei ist ersichtlich zu welchem Zeitpunkt über welche Zeit es Autokorrelationen gibt. Bitcoin ist dabei am effizientesten und alle Kryptowährungen werden über die Zeit effizienter. Jedoch gibt es Zeiträume in denen Potenzial für profitables Trading besteht (Fidrmuc et al., 2020).

Die schwache Markteffizienz lässt sich jedoch auf andere Wege überprüfen als mithilfe von statistischen Tests. Einer dieser Wege ist eine Trading-Strategie gegen eine Buy-Hold-Strategie anzuwenden. In unserem Fall der schwachen Markteffizienz können keine Informationen gebraucht werden, die nicht dem historischen Preis entnommen werden können. Paper welche Tweets von Elon Musk und das Zusammenspiel mit dem Bitcoinpreis analysieren sind somit nicht Bestandteil dieser Arbeit.

Innerhalb der bestehenden akademischen Literatur besteht jedoch das grundlegende Problem, das sehr oft bloss nur unterschiedliche programmier-technische Lösungen für Preisvorraussagen bei Kryptowährungen verglichen und getestet werden und die ökonomische Perspektive oft vergessen wird. Dies ist ersichtlich zum Beispiel bei (Lahmiri and Bekiros, 2019) oder (Han et al., 2020). Eine der ersten Paper in diesem Bereich ist das von Jiang und Liang (2017). Ihnen gelang es in einem kurzen Zeitintervall

von 1 Jahr in 15-minütigen Zeitintervallen die Buy-Hold-Strategy zu übertreffen und auch gleichzeitig eine Sharpe-Ratio von über 1 zu erzielen (Jiang and Liang, 2017). Den kurzen Zeitintervall verlängerte Nakano (2018) auf 2 Jahre und zeigt auf wie Resultate bei Anwendung von ANN schwanken können. Die Resultate sind sehr stark abhängig von den Modellspezifikationen und den Input-Daten, nichtsdestotrotz wird Buy-Hold geschlagen (Nakano et al., 2018). ANN zeigt sich 2019 mit de Souza et al. (2019) und Atsalakis et al. (2019) als eine suboptimale Methode. ANN übertrifft Buy-and-Hold nur in Perioden von sehr starken Bull-Runs und diese Überperformance ist nicht genügend gross um in ruhigen Zeiten kompensieren zu können (Silva de Souza et al., 2019). PATSOS ist hingegen fähig konsistent die Buy-Hold-Strategy zu schlagen, jedoch bleibt ein standardisierter Vergleich mithilfe dem Sharpe oder Sortino-Ratio aus (Atsalakis et al., 2019). Huang et al. (2019) gelingt mithilfe von Klassifikationsbäumen eine Strategie zu schaffen welche tiefere Volatilität, höhere win-to-loss ratio und information ratio als Buy-Hold hat. Gleichzeitig besitzt sie auch eine grössere Sharpe-Ratio als von 1 (Huang et al., 2019). Die RSM wird als eine Methode, welche Buy-Hold schlagen könnte ausgeschlossen (Shintate and Pichl, 2019).

Eine Kombination der statistischen Tests und der Trading-Strategien versuche Bundi et al – sie untersuchten die SMH bei Bitcoin mit Hilfe von einem GARCH-Test. Sie finden eine Autokorrelation beim lag von 6 Tagen und Evidenz gegen die SMH. In einem zweiten Teil vergleichen sie eine Trading-Strategie und eine Buy-Hold-Strategie in einer praktischen Anwendung. Sie wenden dabei drei Strategien an, eine momentumbasierte, zeitreihenbasierte und eine auf neuronalen Netzwerken bauende Strategie. Dabei Schnitt am besten das Zeitreihen-Modell am besten ab. Im Unterschied somit zu vorgängiger Literatur verwerfen sie die SMH bei Bitcoin. Andere Kryptowährungen sind nicht Bestandteil dieses Papers (Bundi and Wildi, 2019).

Im Gegensatz steht das Paper von Grobys und Sapkota (2019), welche sich ausschliesslich mit der Momentumstrategie auseinandersetzen. Im Unterschied zu Bundi und Wildi (2019) analysieren sie nicht nur Bitcoin, sondern alle Kryptowährungen, welche sich per 28 Dezember 2014 unter den grössten 30 befindet haben. Sie finden keine statistisch signifikante Frequenz bei der sich eine Momentumstrategie sich lohnen würde (Grobys and Sapkota, 2019).

Es lässt sich somit abschliessend sagen, dass kein absoluter Gewinner unter den Möglichkeiten mit künstlicher Intelligenz mit Kryptowährungen zu handeln existiert. Es

ist ersichtlich das in der bisherigen Literatur Wege bestehen mithilfe deren Buy-Hold geschlagen werden kann. Jedoch sind diese, der aktuellen Literatur entsprechend, limitiert auf Zeitperioden, welche entweder kurz oder sich in Bull-Runs befinden. Somit findet das Ziel, fundamentale längerfristiger Ineffizienzen zu suchen oder zu widerlegen Bestätigung. Solche Unsicherheit besteht aber nicht bei der semi-starken Markteffizienz, wo der Markt immer noch eindeutig ineffizient ist (Sebastião and Godinho, 2021).

2 Methodologie

Wir werden somit 2 Wege in der Methodologie gehen um die schwache Markteffizienz zu testen. Einerseits wird es um statistische Tests gehen, welche in der akademischen Literatur mehrfach für unterschiedliche Zeitperioden repliziert wurden und alle auf dem Paper von Urquhart (2016) aufbauen wie zum Beispiel (Nadarajah and Chu, 2017), (Brauneis and Mestel, 2018) und (López-Martín et al., 2021). Das Ziel ist es die Paper zu verifizieren und deren Arbeit auf weitere Kryptowährungen und Tests auszuweiten die bis anhin nicht teil der Forschung waren. Andererseits werden Trading-Strategien verwendet welche auf den Momentumstrategien basieren.

2.1 Daten

In der akademischen Literatur gibt es keine Eindeutige verwendete Datenquelle. Gewisse Akademiker verwenden Daten direkt von den Börsen (Fidrmuc et al., 2020). Andere verlassen sich auf Plattformen welche die Börsendaten sammeln und gewichtet Mitteln (Urquhart, 2016). Einerseits ermöglichen die Plattformen einen schnellen Zugriff auf viele Kryptowährungen mit vielen Parametern. Die Plattformen garantieren auch einen viel längeren Zeithorizont da viele Börsen heute nicht mehr existieren oder nicht alle Kryptowährungen während ihrer Existenz handelten (Vidal-Tomás, 2022). Gleichzeitig ermöglichen sie eine Unterscheidung der Börsen in ihrem Marktanteil und der Liquidität. Problematisch werden diese wenn merkliche Preisunterschiede vorhanden sind und somit Arbitragepotential besteht. Es wäre auch denkbar das Preise bei den Börsen Gegenläufig sind. Gleichzeitig können auch bei der eigentlichen Sammlung der Informationen Probleme bestehen. Diese Probleme wurden in der Publikation von Vidal-Tomás (2022) beleuchtet. Er analysierte die Verlässlichkeit diverser Plattformen die Informationen über Kryptowährungen sammeln und daraus einen Preis, Volumen und weiteres generieren. Dabei kommt er zum Schluss das grundsätzlich keine markanten Unterschiede zwischen

dem Verhalten auf den Börsen und den Datenbanken bestehen. Er empfiehlt aus den von mir genannten Gründen auch die Verwendung der Plattformen (Vidal-Tomás, 2022). Für die gewählten Zeitbereiche wurden Bereiche gewählt, seit dem Einführungsdatum der Kryptowährung oder bei älteren Kryptowährungen der 29.4.2013. Seit diesem Zeitpunkt sind Daten auf den von mir gewählten Plattformen verfügbar. Ich wählte dabei aus seiner Arbeit die Plattform «coinmarketcap.com», wegen der einfachen Verfügbarkeit ihrer Daten, über das R-Package «crypto2», aus. Mithilfe dieses R-Package ist es möglich die von Ihnen öffentlich verfügbaren Informationen von der Webseite mit Hilfe von Screen Scraping zu erhalten. Das Package ist dank der Open-Source-Lösung über R öffentlich einsehbar (Stöckl, 2022).

2.2 Statistische Tests zur Überprüfung der schwachen Markteffizienz

Zuerst werden einige deskriptive Beobachtungen gemacht. Merkmale wie Skewness, Kurtosis und der Jarque-Bera-Test zusammen mit dem Maxima, Minima, Median und Durchschnitt geben eine heuristische Einsicht über die Daten.

In dieser Arbeit werden diverse Hypothesen formuliert welche Evidenz dafür liefern, dass die gegebene Kryptowährung schwach Markteffizient ist. Diese Hypothesen betreffen die Eigenschaften die Grundgesamtheit der Preiswerte. Die einzelnen Hypothesen unterscheiden sich in ihren Voraussetzungen und der Strengheit ihrer Aussagen. Es wird wichtig die Ergebnisse von Tests mit strengeren Voraussetzungen nur als relevant zu betrachten falls dessen Voraussetzungen durch zum Beispiel nicht-parametrischen Test, d.h. ohne Verteilungsannahmen, bestätigt werden. Bei einem Thema wie diesem darf man bei der Grundgesamtheit nicht von statistischer Unabhängigkeit, Absenz von Autokorrelation oder Homoskedastizität ausgehen, ohne diese vorhin geprüft zu haben. Die erste Hypothese ist die der Autokorrelation. Positive Autokorrelation würde indizieren, dass innerhalb einer Frequenz der Markt sich in die gleiche Richtung bewegt. Ich überprüfe diese mithilfe dem Ljung-Box Test (LB). Dieser benötigt keine Normalverteilung (Ljung and Box, 1978).

(1) Ljung-Box Test

T ist die Grösse der Grundgesamtheit, \hat{p} die Autokorrelation bei Lag k, h ist die Anzahl Lags die getestet wird

$$LB(k) = T(T+2) \sum_{k=1}^m \frac{1}{T-k} \hat{p}^2(k) \sim X_m^2$$

Zweitens wende ich den variance ratio Test von MacKinlay und Lo (1988) an. Die Nullhypothese dieses Tests ist das der Preisprozess einem Random Walk folgt, die Renditen sind somit unkorreliert und sie sollten dabei linear über die Zeit ansteigen (MacKinlay und Lo, 1988). Dabei sollte die Varianz der Preise im Abstand von k, der Varianz des ersten Preisschrittes mal k entsprechen. Gleichzeitig wird Messung in l Unterbereiche unterteilt in denen eine solche Untersuchung stattfindet. Problematisch bei diesem Test ist die Wahl von l und k und somit verwende ich die Datengestützte Methode von (Choi, 1999). In der Literatur wird weiterhin diese Methode mit den Verbesserungen von (Kim, 2009). Dieser verbesserte die Eigenschaften dieses Tests vor allem bei kleinen Stichproben (Kim, 2009). Bei diesem Test verlasse ich mich auf das R-Package «vrtest» dessen Autor Kim selber ist (Kim, 2014).

(2) Variance Ratio Test

r_i ist die Rendite, T die Anzahl der Beobachtungen, l ist die Anzahl perioden in die Messung unterteilt wird, k ist die Anzahl Messungen in einer Unterteilung

$$\widehat{VR}(l) = 1 + 2 \sum_{i=1}^{T-1} k \binom{i/l}{i} \hat{p}(i), \quad \hat{p}(i) = \sum_{t=1}^{T-i} \Delta r_t \Delta r_{t+i} / \sum_{t=1}^T r_t^2$$

Der dritte verwendete Test ist der Runs-Test. Dieser Testet nichtparametrisch eine Folge auf Zufälligkeit. Dabei wird bei metrischen Merkmalen die Folge dichotomisiert. Man bestimmt den Median der Folge. Dieser unterteilt die Werte dementsprechend in Werte oberhalb und unterhalb des Medians. Die Nullhypothese dabei ist das die Renditen unabhängig voneinander sind (Wald and Wolfowitz, 1940).

(3) Run-Test

n ist die Anzahl Messungen, n_1 ist die Anzahl Messungen über dem Median, n_2 ist die Anzahl Messungen unter dem Median, r ist die Anzahl Runs

$$RUN = \frac{r - \left(\frac{2n_1n_2}{n} + 1\right)}{\sqrt{\frac{2n_1n_2(2n_1n_2 - n)}{n^2(n_1 + n_2 - 1)}}}$$

Der letzte Test ist der Hurst-Exponent (Hurst, 1951). Dieser wird standartweise verwendet um langfristige Reminiszenzen zu Erkennen. Bei diesem ist es schlussendlich nicht sinnvoll ein p-Wert wiederzugeben da der eigentliche Wert mehr Informationen zur Verfügung stellt. Er kann Werte zwischen 0 und 1 annehmen. Bei einem Wert von genau 0.5 entspricht der Prozess einem Random-Walk. Bei Werten oberhalb von 0.5 besteht eine langfristige positive Autokorrelation bei Werten von unterhalb 0.5 ist sie negativ. Als signifikant ineffizient werden Werte ausserhalb des Intervalls 0.45 bis 0.55 betrachtet (Hurst, 1951).

(4) Hurst Exponent

n ist die Anzahl Messungen, X_i sind die einzelnen Messungen

$$Y_t = X_t - \frac{1}{n} \sum_{i=1}^n X_i \text{ for } t = 1, 2, \dots, n$$

$$Z_t = \sum_{i=1}^t Y_i \text{ for } t = 1, 2, \dots, n$$

$$R(n) = \max(Z_1, Z_2, \dots, Z_n) - \min(Z_1, Z_2, \dots, Z_n)$$

$$S(n) = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - m)^2}$$

$$HURST = \log(R(n)) / \log(S(n))$$

Alle statistischen Tests werden für komplette fixe Zeitfenster betrachtet. Dabei unterteilen wir die Zeitreihe in 2 Zeitfenster. Im Anschluss werden diese Tests über verschieden lange fortlaufende Fenster berechnet. Somit entsteht ein tägliches Testergebnis.

2.3 Trading-Strategien

Im zweiten Teil wird jeweils eine Buy-and-Hold Strategie mit aktivem Trading verglichen. Der Vergleich basiert schlussendlich auf einem Vergleich der Gesamtrendite, Vergleich der Grundgesamtheiten der Renditen mithilfe einem Wilcoxon-Vorzeichen-Rang-Test, Vergleich und Prüfung der Sharpe-Ratios auf signifikanten Unterschied und einem Vergleich der Sortino-Ratios. Der Wilcoxon-Vorzeichen-Rang-Test ist ein non-parametrischer Test welcher zwei Grundgesamtheiten vor und nach einer Behandlung vergleicht. Er benutzt dabei nicht die Durchschnitte sondern vergleicht die gesamthaften Grundgesamtheiten und umgeht somit die Annahmen über die Verteilung der Grundgesamtheiten. Gleichzeitig können auch die Einschränkungen des Sharpe oder Sortinos-Ratio umgangen werden.

Als das risikoadjustierte Mass der Renditen wird das Sharpe und Sortino Ratio verwendet. Das Sharpe Ratio stellt die Gesamtrendite im Vergleich zum Risiko, ausgedrückt in der Standardabweichung dar. Beim Sortino-Ratio wird nur die Standardabweichung der negativen Renditen berechnet.

Bei den Trading-Strategien wurden explizit solche gewählt, welche konsistent in Tradition mit den in der klassischen Finance verwendeten stehen. Bei künstlicher Intelligenz oder neuronalen Netzwerken besteht das Problem, das diese eine «black-box» sind und uns eine Analyse der Herkunft der Ineffizienz verwehrt wird.

Die in dieser Arbeit verwendeten Strategien sind beide momentumbasiert. Bei dieser Strategie wird probiert zu erkennen, in welche Richtung sich der Markt bewegt und dementsprechend ex ante für den nächsten Trade zu bestimmen, ob man long oder short gehen soll. In dieser Arbeit wird diese Entscheidung aufgrund zwei Methoden getroffen. Dem Chande Momentum Oscillator (CMO) und dem David Varadi Indicator. Beim Chande Momentum Oscillator muss zuerst die Anzahl Lags bestimmt werden über welche diese Strategie verwendet wird. Dabei werden wir uns auf die Ergebnisse vom Ljung-Box-Test verlassen.

(5) Chande Momentum Oscillator

$$CMO = \frac{sH - sL}{sH + sL} \times 100$$

Dabei ist sH, die Summe der positiven Renditen und sL die Summe der negativen im Zeitfenster. Über die Periode wird anschliessend ein laufender Durchschnitt des CMO

berechnet, falls der aktuelle Wert unter dem laufenden Durchschnitt ist, kann dies als Signal zum Verkauf interpretiert werden. Umgekehrt ist dies ein Signal zum Kauf (Chande and Kroll, 1994).

Zweitens wird der David Varadi Indicator verwendet. Dieser kombiniert laufende Durchschnittsrenditen über unterschiedliche Zeitfenster und die relative Anzahl von positiven und negativen Renditen über unterschiedliche Zeitfenster. Diese beiden Komponenten können unterschiedlich gewichtet werden und die Anzahl der Zeitfenster sind 3.¹

3 Empirische Erkenntnisse

In diesem Teil werden die Resultate betrachtet. Zuerst werden die Daten rein deskriptiv analysiert. Daraufgehend werden die diversen statistischen Tests durchgeführt. Im dritten Teil werden die Erkenntnisse aus dem zweiten Teil praktisch angewendet.

2.1 Deskriptive Statistik

Die deskriptiven Daten wurden aufgrund der stetigen Tagesrenditen berechnet. Es ist ersichtlich das die Daten nicht klassischen Daten aus dem Aktienmarkt oder ähnlichen Gebieten entsprechen. Seit dem Beginn der Beobachtungen hat sich der Bitcoinpreis über 270-verfacht. Bei Dogecoin ist dies über 400-mal. Am schlechtesten schnitt Litecoin ab, der nur sich 24-fachte. Gewisse Kryptowährungen besitzen, eine negative Medianrendite. Die Kurtosis weist darauf hin, dass es sich um Daten mit fat-tails handelt. Aus der Skewness und der Kurtosis errechnete Jarque-Bera-Test zeigt, das zunächst die Daten nicht einer Normalverteilung entsprechen. Dies gilt für alle Kryptowährungen zum Signifikanzniveau von 0. Somit lassen sich auch im späteren Teil keine statistischen Tests verwenden, die diese Voraussetzung benötigen. In dieser Arbeit wurden auch keine solchen Tests verwendet. Die betrachteten Zeitbereiche sind ab dem 29.4.2013 oder seit der Einführung der Kryptowährung.

¹ Die Berechnung des DVI ist in der beigelegten Datei ersichtlich. Der Wilcox-Test wird nicht explizit behandelt, da dieser nicht eine Schlüsselrolle innerhalb dieser Arbeit spielt.

Abbildung 2
Deskriptive Statistik

Bei den Renditen handelt es sich um stetige Tagesrenditen. Die behandelten Zeiträume sind rechts vermerkt, die Anfangsdaten werden in den darauffolgenden Untersuchungen verwendet und nicht wieder vermerkt. Signifikanzcodes für Jarque-Bera: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Währung	Zeitbereich	D-Rendite	Median	Maximum	Minimum	Kurtosis	Skewness	Jarque-Bera
Bitcoin	2013-04-29 2022-04-24	0.17%	0.18%	36%	-46%	10.93	-0.51	0***
Ethereum	2015-08-07 2022-04-24	0.28%	0.8%	41%	-130%	69.11	-3.21	0***
Litecoin	2013-04-29 2022-04-24	0.10%	0.6%	83%	-51%	23.53	1.16	0***
Monero	2014-05-21 2022-04-24	0.18%	0.12%	58%	-53%	8.82	0.26	0***
Stellar	2014-08-06 2022-04-24	0.15%	-0.18%	72%	-41%	16.76	1.77	0***
Ripple	2013-08-05 2022-04-24	0.15%	-0.20%	103%	-62%	26.79	1.59	0***
Dogecoin	2013-12-15 2022-04-24	0.21%	-0.21%	152%	-58%	62.30	3.78	0***

Abbildung 3
AVR-, Hurst- und Runs-Test über gegebene Zeiträume

Die Anfangsdaten für den kompletten Zeitraum und die erste Unterteilung sind in Abbildung 2 vermerkt. Das Anfangsdatum für die zweite Unterteilung ist der 01.01.2019.

Signifikanzcodes für AVR- und Runs-Test: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$ Signifikanz für Hurst-Exponent: * Hurst > 0.55 oder Hurst < 0.45

Zeitraum und Währung	AVR ges. Zeitraum	bis 31.12.2018	bis 24.04.2022	Hurst ges. Zeitraum	bis 31.12.2018	bis 24.04.2022	Runs-Test ges. Zeitraum	bis 31.12.2018	bis 24.04.2022
Bitcoin	0.66	0.876	0.138	0.53	0.56*	0.54	0.0079***	0.48	0.0015***
Ethereum	0.284	0.026**	0.122	0.57*	0.60*	0.555*	0.006***	0.86	0.0015***
Litecoin	0.886	0.702	0.252	0.53	0.56*	0.51	0.0002***	0.0028***	0.038**
Ripple	0.376	0.28	0.586	0.54	0.56*	0.51	0.35	0.079*	0.00036***
Dogecoin	0.628	0.556	0.804	0.51	0.52	0.579*	0.002***	0.004***	0.018**
Stellar	0.304	0.306	0.692	0.55	0.57*	0.553*	0.002***	0.001***	0.024**
Monero	0.348	0.756	0.03**	0.56*	0.58*	0.522	0.0001***	0.028**	0.0015***

2.2 Statistische Tests zur Überprüfung der schwachen Markteffizienz

Zuerst werden die statistischen Tests über den ganzen Zeitraum, der je bei einer Kryptowährung zur Verfügung stehen, angewendet. Einzig bei dem Ljung-Box Test ist noch ein frei wählbarer Parameter vorhanden, dies ist die Länge des Lags. Dieser wird variiert. Anschliessend unterteilen wir die Daten in vor und nach dem 31.12.2018. Mit dieser Unterteilung ist es möglich bei allen Währungen und Tests eine genügend grosse Anzahl Daten zu haben, um einen Trend in den letzten 3 Jahren festzustellen.


2.2.1 Statische Untersuchungen

Es ist ersichtlich das der AVR-Test indiziert, das im gesamtem Zeitraum die einzelnen Kryptowährungen effizient waren. Die Ausnahme bildet Ethereum bis zum 31.12.2018 und Monero ab diesem Datum, wenn wir die Unterteilung miteinbeziehen. Die Varianzen scheinen, dem AVR-Test folgend, über die Zeit, mit einigen Ausnahmen konstant zu sein. Dies ist Evidenz dafür, dass in der Zukunft auch ruhig homoskedastische statistische Verfahren gebraucht, werden könnten. Beim Hurst Exponent ist ein ähnliches Bild vorhanden, ausser bei Monero, Ethereum und Ripple, wo wir Evidenz für Ineffizienz haben. Bei allen Kryptowährungen, ausser bei Dogecoin, verbesserte sich auch die Effizienz im zweiten Unterteilungszeitraum. Dies deutet darauf hin, dass die Entwicklung welche diese Kryptowährungen seit dem 31.12.2018 durchgemacht haben, nicht auf eine langfristige Autokorrelation deutet. Bei dem Runs-Test zeigt sich ein anderes Bild ab. Die Kryptowährungen scheinen ineffizient mit einigen Ausnahmen zu sein. Ineffizient in dem Sinn das die Entwicklung, welche sie durchgemacht haben, Runs-basiert ist. Es gibt laut dem AVR-Test keine variierende Varianz, laut dem Hurst Exponent keine langfristige Autokorrelation aber es kann sehr wohl sich wiederholende Runs geben.

Die Erkenntnisse mithilfe des Runs-Test bestätigt der Ljung-Box Test, welcher verwendet wird, um serielle Autokorrelation zu finden. Im Unterschied zum Hurst-Exponent, tut er dies aber bei einer kleinen Zahl von Lags. Ab einem Lag von 6 scheint serielle Autokorrelation bei allen Kryptowährungen vorhanden zu sein, mit einigen Ausnahmen wie Stellar. Dies deutet darauf hin, dass eine momentumbasierte Tradingstrategie Erfolg haben könnte.

Abbildung 4
Ljung-Box Testresultate

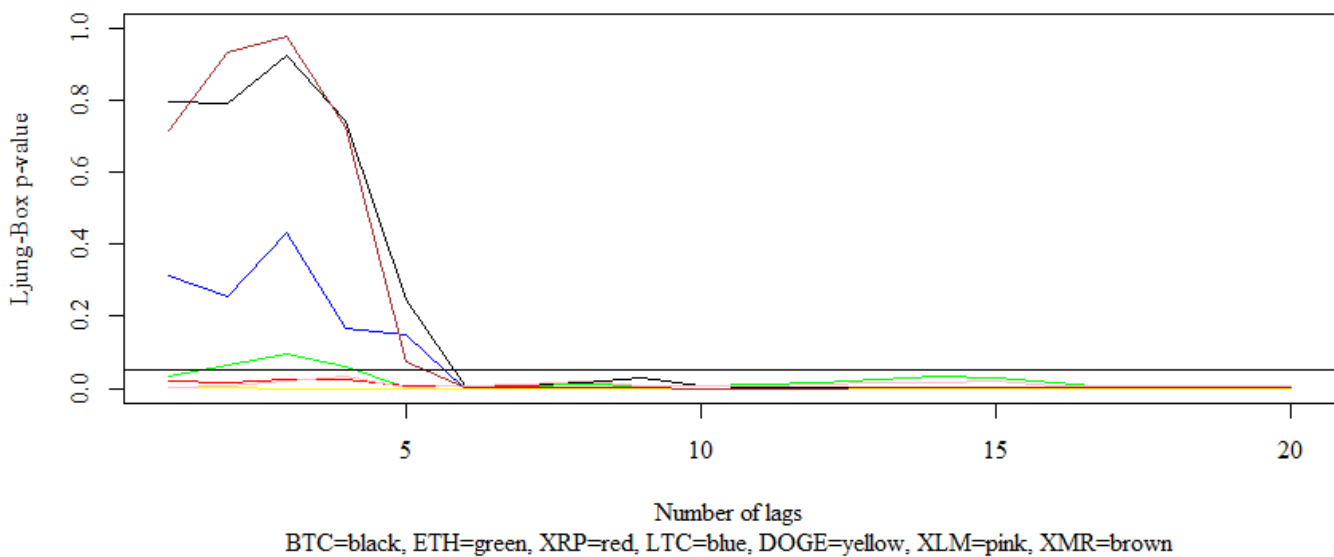
Über den kompletten Zeitraum bei variierender Anzahl von Lags. Wagrechte Linie liegt bei dem Wert von $p = 0.05$.



Bei einer Unterteilung in die 2 Zeiträume ist die Situation in der Periode bis zum 31.12.2018 gleich wie im Gesamtzeitraum. Alle Kryptowährungen sind ab einem Lag von 6 ineffizient und es ist serielle Autokorrelation vorhanden.

Abbildung 5
Ljung-Box-Test bis 31.12.2018

Über den kompletten Zeitraum bei variierender Anzahl von Lags. Wagrechte Linie liegt bei dem Wert von $p = 0.05$.

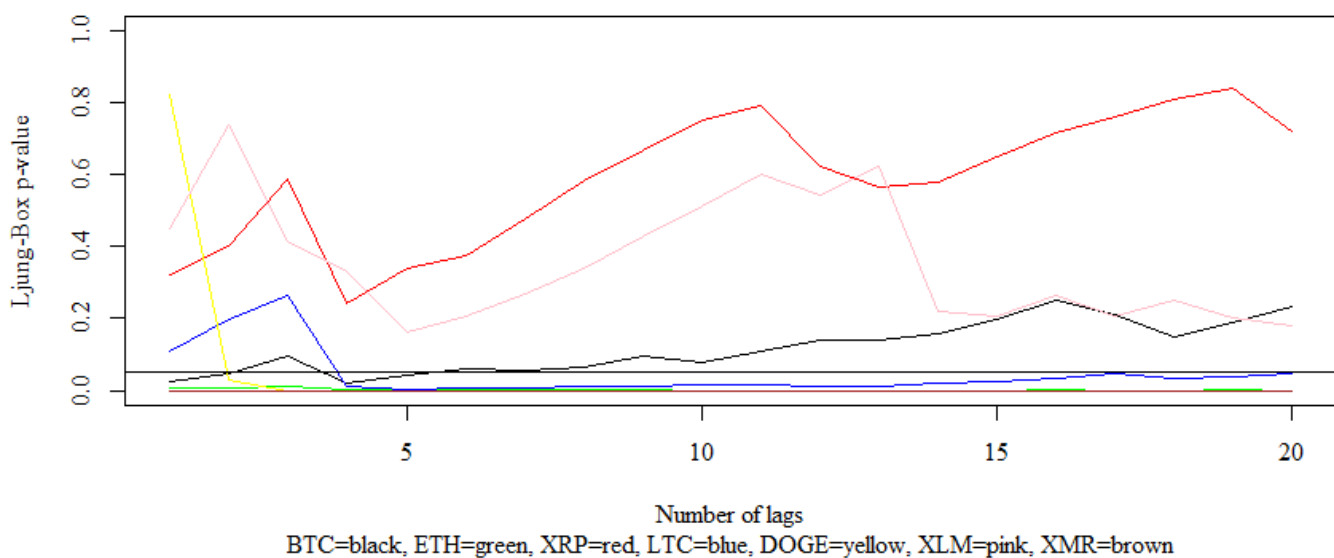


Im zweiten Zeitraum jedoch, d.h. ab dem 01.01.2019, scheint eine einfache Autokorrelation nicht mehr immer vorhanden zu sein. Es sind immer noch Lags vorhanden, in diesem Fall der von 4 Tagen, wo alle Kryptowährungen ausser Ripple und Stellar mit sich selber korrelieren. Bei einer höheren Anzahl von Lags ist auch Bitcoin nicht mit sich selber korreliert. Es ist somit nicht sicher ob eine Momentumstrategie so sicher gebraucht werden kann, wie in der ersten Zeitperiode.

Abbildung 6

Ljung-Box-Tests vom 1.1.2019 bis 24.04.2022

Über den kompletten Zeitraum bei variierender Anzahl von Lags. Wagrechte Linie liegt bei dem Wert von $p = 0.05$.



2.2.2 Dynamische Untersuchungen

In diesem Teil werden die Resultate der Tests präsentiert, wenn sie auf ein laufendes Zeitfenster angewendet werden. Es wurde das Zeitfenster von 350 Tagen gewählt. Die graphischen Resultate sind im Anhang ersichtlich. Bei einer Veränderung der Zeitfensterlänge auf 200 oder 500 Tage bleiben die Resultate gleich.

Bei einem fortlaufendem Zeitfenster von 350 Tagen ergibt der AVR-Test die gleichen Resultate wie in den vorigen Untersuchungen. Es gibt somit Evidenz, ausser bei Monero und Stellar bei kurzen Zeitperioden, für konstante Varianzen. Der Hurst Exponent gibt ein ähnliches Bild wieder. Die Kryptowährungen sind sicher nicht langfristig negativ autokorreliert, ausser für eine kurze Zeitperiode von Stellar in 2016. Mit den jeweiligen Bull-Runs zusammenhängend entstehen jedoch langfristige positive Autokorrelationen. Am stärksten sind diese in der Vergangenheit gewesen, der letzte Bull-Runs scheint nicht mehr so extrem gewesen zu sein. Dies ist an Bitcoin zum Beispiel ersichtlich. Der Runs-

Test hingegen zeigt ein etwas anderes Bild als in der statischen Version. Es gibt Zeitperioden, in denen dieser wie in der statischen Version darauf hindeutet, dass der Markt ineffizient ist. Dies bedeutet das es Runs gibt. Auf der anderen Seite gibt es bei einzelnen Kryptowährungen in Zeitperioden wo der Markt laut der statischen Methode ineffizient sein sollte beträchtliche Zeitabstände, wo er effizient ist. Dies ist Evidenz dafür, das allfällige sich wiederholende Runs bei einer Verlängerung des Zeitfensters sich häufen.

Bei den fortlaufendem Ljung-Box Test wurde ein Lag von $n=5$ gewählt. Der Lag von 5 wurde gewählt da in den statischen Untersuchungen auf der Grenze zwischen Effizienz und Ineffizienz befand. Bei den Resultaten ist ein abwechslungsreicheres Bild als bei den anderen Tests vorhanden. Jede Kryptowährung hat Zeitperioden, in denen es Evidenz dafür gibt, das serielle Autokorrelation bei einem Lag von 5 herrscht. Dabei lässt sich die Beobachtung in drei Bereiche teilen. In einer Phase bis 2018 war der Preisbildungsprozess, dem Ljung-Box Test folgend, zufällig. Nur Ripple und Stellar besitzen langfristige Zeitbereiche in denen dies nicht der Fall ist. Ab 2018 bis 2020 scheint serielle Autokorellation bei fast allen Kryptowährungen vorhanden gewesen zu sein. Diese Zeitperiode ist zwischen dem Bull-Run von 2017 und dem vom Ende 2020 und zeichnet sich aus mit einer geringen Volatilität im Vergleich zur Vergangenheit aus. Spätestens ab 2022 sind die meisten Kryptowährungen wieder effizient geworden.

2.3 Trading-Strategien

In diesem Abschnitt werden die momentumbasierten Tradingstrategien beleuchtet. Zuerst werden die stetigen Tagesrendite über einen Wilcoxon-Test verglichen. Dieser hat als Nullhypothese das ein zufällige Probe nicht mit mehr als einer 50-prozentiger Wahrscheinlichkeit grösser ist als eine zufällige Probe der anderen Menge. Dabei werden die gesamten Grundmengen verglichen und nicht Erwartungswerte selbst. Anschliessend sind die Sharpe-Ratios und ein Chi-Squared-Test zum Vergleich der Sharperatios erfasst worden. Die Nullhypothese von diesem Test ist, ist das die Sharpe-Ratios sich nicht statistisch signifikant unterscheiden. Im Anschluss werden noch die Sortino-Ratios verglichen.

2.3.1 Chande Momentum Oscillator

Der verwendete Zeitraum ist bei jeder Kryptowährung der für den Daten innerhalb dieser Arbeit vorhanden sind. Es wurde täglich ein Trade durchgeführt. Allfällige Gebühren für Trading werden nicht einbezogen. Bei dieser einfachen Methode wurden die Resultate aus dem Ljung-Box angewendet. Das Zeitfenster über das der CMO berechnet und dessen fließender Durchschnitt gebildet wird liegt bei 10. Das durch CMO berechnete Signal wurde, laut in der Methodik präsentierter Weise, entweder in 1 oder -1 umgedeutet. Dies heisst das man den nächsten Tag entweder long oder short ging. Die Buy-Hold Strategie ist das einfache halten der Währung seit dem ersten Handelstag.

Bei jeder Kryptowährung schnitt die CMO-Strategie besser ab als die Buy-Hold-Strategie. Dies zeigt der Wilcox-Test oder der Chi-Squared-Test zum Vergleich der Sharpe-Ratios. Somit wurden die Gewinne nicht mit einem höherem Risiko erkaufte. Die Unterschiede sind bei dem Sortino-Ratio noch grösser als bei dem Sharpe-Ratio. Der grösste Unterschied, laut dem Sharpe-Ratio, ist bei Litecoin. Der kleinste Unterschied, laut dem Sharpe-Ratio, bei Ethereum.

Abbildung 7
Vergleich der CMO-Trading Strategie und Buy-Hold Strategie.
Signifikanzcodes für Wilcox- und Chi-Squared-Test: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

	BTC	XRP	LTC	DOGE	XLM	XMR	ETH
Wilcox-Test	0***	0***	0***	0***	0***	0***	0***
SR CMO	3.98	4.06	3.87	3.63	4.18	4.25	4.11
SR Buy-Hold	0.67	0.34	0.27	0.42	0.35	0.43	0.88
Chisq-test SR	0***	0***	0***	0***	0***	0***	0***
STR CMO	6.59	7.98	7.26	6.74	8.04	7.98	6.93
STR Buy-Hold	0.816	0.497	0.37	0.67	0.57	0.62	1.19

2.3.2 David Varadi Indicator

In diesem Fall wurde getestet ob eine spezifische Trading-Strategie mit den Parametern nicht angepasst für den Kryptomarkt auch hier erfolgreich sein wird. Es wurde wie im Fall der CMO-Strategie das komplette Zeitfenster entnommen für das Daten innerhalb dieser Arbeit vorhanden sind. Wie im letzten Fall wurden Tagespreise und Trades im Eintagesrythmus durchgeführt. Auch hier wurde das errechnete Signal entweder in 1 oder -1 umgedeutet.

Im Unterschied zur CMO-Strategie konnte bei Monero, Bitcoin und Ethereum für ein Signifikanzniveau von 0.05 bei dem Wilcox-Test die Buy-Hold Strategie nicht übertroffen werden. Bei den Sharpe-Ratio wird dies für ein Signifikanzniveau von 0.05 nur bei Monero bestätigt. Bitcoin und Ethereum sind bei einem Signifikanzniveau von 0. Es zeigt sich, dass nicht unbedingt, die bei der CMO-Strategie präsentierten Gewinne, sich wiederholen müssen. Es ist bemerkenswert, dass die beiden grössten Kryptowährungen Bitcoin und Ethereum und 2 von 3 in dieser Arbeit miteinbezogenen proof-of-work Kryptowährungen, Bitcoin und Monero sich effizient verhalten. Die 3. ist Litecoin.

Abbildung 8

Vergleich der DVI-Trading Strategie und Buy-Hold Strategie.

Signifikanzcodes für Wilcox- und Chi-Squared-Test: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

	BTC	XRP	LTC	DOGE	XLM	XMR	ETH
Wilcox-Test	0.22	0***	0***	0***	0.0002***	0.16	0.05
SR DVI	1.51	1.80	1.71	1.54	1.44	1.32	1.83
SR. Buy-Hold	0.62	0.40	0.20	0.52	0.37	0.63	0.75
Chisq.-test SR	0.04**	0***	0***	0.0002***	0.005***	0.092*	0.02**
STR DVI	2.26	2.78	2.70	2.52	2.33	2.19	2.85
STR Buy-Hold	0.75	0.60	0.27	0.83	0.60	0.90	1.00

3 Diskussion

Im ersten Schritt wurde beleuchtet in welcher Weise sich die Marktinneffizienz äussern könnten. Mit der gewonnenen Information wurde versucht dies praktisch anzuwenden. Die statistischen Tests zeigen gemischte Ergebnisse. Der AVR Test zeigte das grundsätzlich alle Kryptowährungen, über die meiste Zeit markteffizient waren. Der AVR Test zeigt das es keine variierenden Varianzen gibt und somit die in gewisser Literatur verwendeten ARCH-Tests gar nicht notwendig sind. Der Hurst Test zeigt, dass ausser in den Bull-Run Perioden, die Kryptowährungen sich mehrheitlich effizient verhalten haben. Es ist jedoch fraglich ob eine solche positive Autokorrelation nicht grundsätzlich bei jeder neuer Technologie oder Aktien von Startups besteht. Bei der Anwendung des Runs Test gibt es bereits Evidenz für Ineffizienz. Anschliessend wurde gefunden das die Quelle dieser Ineffizienz teilweise in einer Autokorrelation liegt. Dies wurde mithilfe des Ljung-Box Tests gezeigt. Die Autokorrelation ist bei höheren Lags als 6 zu beobachten. Die Tests zeigen somit, dass die Kryptowährungen eine Tendenz zu Ineffizienz während den Bull-Runs haben und das die durch den Runs-Test gemessene Marktinneffizienz zumindest teilweise durch Autokorrelation erklärbar ist. Die in dieser Arbeit erstellten Resultate bestätigen die limitiert vorhandenen Daten aus der bestehenden Literatur. Es handelt sich dabei vor allem um Bitcoin (Urquhart, 2016) und den AVR-Test, Ljung-Box-Test, Hurst-Exponent (López-Martín et al., 2021). Hingegen eine Währung wie Dogecoin ist in mir keiner bekannter Literatur mit diesen Methoden behandelt worden. Im weiteren ist eine Anwendung der Tests auf so einen langen Zeitraum ein Unikat. Der Runs-Test ist auch noch nie mit einem rollendem Fenster verwendet worden.

Bei den Schlussfolgerungen welche getroffen wurden gibt es Widersprüche zu bestehender Literatur. Es gibt in dieser Arbeit keine eindeutige Entwicklung der Effizienz. Somit konnte die adaptive Markthypothese nicht bestätigt werden. Dies ist vermutlich dem so da es sich immer noch um eine neue Technologie handelt und der Alterungsprozess sehr langsam voran geht. Sicher langsamer als vermutet wurde (Urquhart, 2016). Somit stehen diese Resultate im Gegensatz vor allem der jüngeren Literatur wie Urquhart und der in der der letzte Bull-Run von 2021 nicht mit einbezogen wurde (López-Martín et al., 2021). In beiden Fällen wurde vermutet das sich der Markt adaptiert.

Die Stärke der Marktinneffizienz wird darauffolgend auch durch die Anwendung bei den Trading Strategien bestätigt. Es kann somit die bestehende Literatur bestätigt werden,

dass gewinnbringendes Trading bei Kryptowährungen möglich ist (Bundi and Wildi, 2019). Bei den Strategien schneidet die einfachere Methode besser ab, vor allem auch da aktiv mit den vom Ljung-Box Test gewonnenen Daten, gearbeitet wird. Diese Anwendung der Resultate vom Ljung-Box-Test in dieser Breite ist auch ein Unikat. Bundi et al mussten sich darauf verlassen, dass irgendwo innerhalb der von ihnen verwendeten Zeitreihe es eine solche Ineffizienz gibt. In dieser Arbeit wird bestätigt, dass über die ganze Zeit bei allen Kryptowährungen diese Ineffizienz sich wiederholt.

3.1 Grenzen der Resultate und weitere mögliche akademische Arbeit

Die in dieser Arbeit beleuchteten Test können nicht komplett abschliessend darauf deuten, wo die Quelle der Marktineffizienz liegt. Die abnormalen Gewinne können sich durch die Autokorrelation vom Ljung-Box Test erklärt werden. Dies jedoch nicht abschliessend. Es sind komplexere Phänomene denkbar, welche in dieser Arbeit nicht gemessen wurden. Eine Möglichkeit wäre zu untersuchen ob die Preise nicht um runde Zahlen wie z Bsp 3000 sich fixiert und sich nicht frei um diese herumbewegt. Untersuchungen zu Montagseffekten wären auch eine Möglichkeit und Evidenz für Marktinneffizienz.

Andere denkbare Untersuchungen könnten, den Kryptomarkt über Portfolios und nicht die Währungen einzeln betrachten. Man könnte untersuchen, ob ein passives Portfolio besser abschneidet als ein aktiv verwaltetes. In diesem Kontext liesse sich zum Beispiel ein CAPM Modell für Kryptowährungen entwickeln. Mann müsste jedoch die hohe Volatilität dieses Marktes in Betracht ziehen. Die einzelnen Währungen wie in der Einleitung präsentiert, wechseln sich ständig in ihrer Grösse ab.

Eine weitere Möglichkeit wäre eine Analyse weiterer Kryptowährungen welche das von mir gestellte Kriterium bei der Auswahl nicht erfüllen. Hier stünde eine Reduktion der Schärfe zur Debatte. Jedoch ist zu beachten das ein Trade-off zwischen der Anzahl der Kryptowährungen und des länge des Zeitraumes über diesen eine Analyse durchgeführt wird besteht. Dies einerseits historisch, zum Beispiel wenn es sich um Kryptowährungen handelt welche nicht 6 Jahre existieren aber auch perspektiv in die Zukunft. Mithilfe der Lindy-Regel wurden solche Kryptowährungen ausgewählt, welche bereits einen gewissen Selektionsprozess durchgemacht haben und auch in Zukunft vorhanden sein werden. Bei sehr jungen Kryptowährungen ist es auch fraglich ob die hier gewählten Methoden überhaupt von der technischen Seite angewandt werden können. Ein anderer

Aspekt ist ob es überhaupt die richtigen Methoden sind oder ob nicht behaviorale Modelle besser geeignet sind.

Im Kontext dieser Arbeit, ist die Thematik des Survivorshipbias auch ein Thema. Die Auswahl meiner Währungen schliesst alle Währungen aus der über längeren Zeit existiert haben aber heute nicht mehr vorhanden sind aus. So könnten sie einerseits effizient oder ineffizient gewesen sein und diese Analyse könnte, in die eine oder andere Richtung verfälscht sein. Es ist einerseits möglich, dass diese Kryptowährungen effizient gewesen waren. Man könnte Effizienz als einen fundamentalen Aspekt für das Überleben einer Kryptowährung ansehen. Eine Kryptowährung welche systematisch Ineffizient und sich nicht adaptiv sich zu einer effizienten entwickelt, muss jemand oder etwas als Quelle dieser Ineffizienz haben. Wenn das Wesen dieser Ineffizienz, zum Beispiel eine konstante Autokorrelation bei einem Lag von 5, immer vorhanden wäre könnte diese durchgehend ausgenutzt werden. In meiner Arbeit ist keine Ineffizienz dieser Art durchgehend über die komplette Existenz einer Kryptowährung vorhanden gewesen. Die Wesen der Ineffizienzen müssen sich zumindest ändern oder zumindest nicht konstant vorhanden sein. Die Seite, die die Ineffizienzen ausnützt, muss eine Gegenseite haben und wenn diese eine und dieselbe über die ganze Zeit wäre und die ökonomischen Verluste hier nicht mehr kompensieren könnte und anschliessend nicht mehr aktiv wäre, würde die Ineffizienz verschwinden. Wenn diese Gegenseite fundamental mit der Währung verbunden ist, zum Beispiel als dessen Verwalter, und diese Ineffizienz aus einem gewissen Feature der Kryptowährung fließen würde, müsste ab einer gewissen Zeit die Kryptowährung durch die Verbindung mit der verlierenden Gegenseite Probleme mit der eigenen Existenz bekommen. Dem folgend würde die in dieser Arbeit präsentierte Effizienz den minimal erreichten Grad an Effizienz des kompletten Kryptomarktes darstellen. Wenn eine der nicht mehr existenten Kryptowährungen fundamental effizienter wäre als die hier beleuchteten Kryptowährungen, wäre es fragwürdig, wieso sie nicht mehr existiert. Es könnte ein Trade-off bestehen, zwischen den Funktionen, die eine Kryptowährung erfüllen muss und der Markteffizienz. Als einer dieser Funktionen wäre die Unabhängigkeit an zentralen Institutionen denkbar. Eine solche zentrale Institution könnte versuchen eine perfekt Markteffiziente Kryptowährung zu kreieren. Bei einer Existenz eines solchen Trade-off gingen die hier präsentierten Währungen den optimalen Weg. Eine effizientere Kryptowährung wäre theoretisch denkbar jedoch in Anbetracht eines solchen Trade-off nicht überlebensfähig. Somit wären die hier

präsentierten Kryptowährungen der maximal erreichbare Grad an Effizienz. Es steht somit zur Frage, welcher dieser Kräfte final stärker ist.

In dieser Arbeit wurden weiterhin mögliche Arbitragemöglichkeiten zwischen einzelnen Börsen nicht thematisiert. Einerseits betrifft dies vor allem die Anfangsphase, d.h. bis 2013, wo es überhaupt keine verlässlichen Daten gibt und andererseits Währungen mit einer tiefen Liquidität (Vidal-Tomás, 2022). In diesem Kontext wären auch Untersuchungen zum Zusammenhang zwischen Liquidität oder anderen Parametern einer Börse und Markteffizienz interessant. Es liesse sich analysieren inwiefern sich die Kryptowährungen auf ihren Börsen im Vergleich zu klassischen Aktiva verhalten. Parameter wie die Möglichkeit und Zugänglichkeit einer API oder das Ausmass der bürokratischen Hürden für den Zugang könnten die Markteffizienz beeinflussen. Eine API ist ein Interface über das zum Beispiel Bots programmiert werden können. Eine Zugänglichkeit könnte viele Investoren anlocken, welche einerseits Markteffizienz durch höhere Liquidität erhöhen andererseits durch gewisses behaviorales Verhalten reduzieren könnten.

4 Schlussfolgerungen

Innerhalb dieser Arbeit wurde gezeigt inwiefern bei einzelnen Kryptowährungen die schwache Markteffizienzhypothese standhält. Dabei wurde eine repräsentative Auswahl von 7 Kryptowährungen getroffen. Es handelt sich dabei um Bitcoin, Litecoin, Ethereum, Dogecoin, Stellar, Stellar und Monero. Diese Wahl basierte auf einer Anwendung der Lindy-Regel statt. Die Daten wurden von der Plattform «coinmarketcap» entnommen. Es wurden Tagespreise und aus dem folgende stetige Tagesrenditen verwendet. Die einzelnen Kryptowährungen wurden zunächst deskriptiv betrachtet. Anschliessend wurden sie mit unterschiedlichen statistischen Tests auf schwache Markteffizienz geprüft. Die Tests wurden aus der bestehenden Literatur inspiriert. Es wurde der AVR-, Runs-, Ljung-Box-Test und der Hurst-Exponent verwendet. Jeder dieser Test liefert Aussagen zu einer gewissen Aussprägung der schwachen Markteffizienz. Zunächst wurde die Zeitreihe in zwei statische Bereiche unterteilt. Anschliessend fand eine dynamische Untersuchung mit einem Zeitfenster von 350 Tagen statt. Die Resultate des AVR-Tests deuten auf effiziente Kryptowährungen hin. Der Hurst-Exponent deutet bei den Bull-Runs auf langfristige positive Autokorrelation hin. Die durchgehend durch den Runstest gemessene Ineffizienz lässt sich durch die kurzfristige Autokorrelation durch den Ljung-Box-Test bei einem Lag von 6 und höher erklären.


Zuletzt wurden die Erkenntnisse aus dem ersten Teil praktisch angewendet. Es wurden zwei Momentumstrategien auf den einzelnen Kryptowährungen getestet. Einerseits der Chande Momentum Oscillator und dessen laufender Schnitt über 10 Tage und andererseits der David Varadi Indicator. Der Chande Momentum Oscillator übertraff bei allen Kryptowährungen die Buy-Hold-Strategie bei jeder Metrik. Als Vergleichsmetrik wurde der Wilcoxon-Rang-Test, der Sharpe-Ratio, ein Chi-Quadrat-Test zu den Sharpe-Ratio und ein Sortino-Ratio verwendet. Bei dem David Varid Indicator, konnte bei Ethereum, Monero und Bitcoin die Tradingstrategie die Buy-Hold-Strategie laut dem Wilcoxon-Rang-Test nicht übertreffen. Dies wurde bei Monero durch den Chi-Quadrat-Test für die Sharpe-Ratios bestätigt. Bei allen anderen Kryptowährungen war die Tradingstrategie besser als die Buy-Hold-Strategie.

Es lässt sich anschliessend nicht sagen das sich die adaptive Markthypothese zumindest jetzt bewarheitet. Bei der Martkineffizienz handelt es vor allem um eine Autokorrelation die an mehreren Zeitpunkten bei den einzelnen Kryptowährungen vorhanden ist. Diese lässt sich anschliessend durch eine Momentumstrategie ausnützen.


Appendix

Im Anhang werden die Resultate der fortlaufenden Tests präsentiert. Die Waagrechte Linie im Fall des AVR-, Runs-, und Ljung-Box-Test liegt bei dem Wert von $p=0.05$. Im Fall des Hurst Exponenten liegt diese bei den Werten 0.45 und 0.55.



A.1 Resultate fortlaufender AVR Test




A.2 Resultate fortlaufender Hurst Exponent






A.3 Resultate fortlaufender Runs Test





A.4 Resultate fortlaufender Ljung-Box Test





Referenzen

- Aggarwal, D., 2019. Do bitcoins follow a random walk model? *Res. Econ.* 73, 15–22.
<https://doi.org/10.1016/j.rie.2019.01.002>
- Andrew W. Lo, A. Craig MacKinlay, Stock Market Prices Do Not Follow Random Walks: Evidence from a Simple Specification Test, *The Review of Financial Studies*, Volume 1, Issue 1, January 1988, Pages 41–66,
<https://doi.org/10.1093/rfs/1.1.41>
- Atsalakis, G.S., Atsalaki, I.G., Pasiouras, F., Zopounidis, C., 2019. Bitcoin price forecasting with neuro-fuzzy techniques. *Eur. J. Oper. Res.* 276, 770–780.
<https://doi.org/10.1016/j.ejor.2019.01.040>
- Böhme, R., Christin, N., Edelman, B., Moore, T., 2015. Bitcoin: Economics, Technology, and Governance. *J. Econ. Perspect.* 29, 213–238.
<https://doi.org/10.1257/jep.29.2.213>
- Brauneis, A., Mestel, R., 2018. Price discovery of cryptocurrencies: Bitcoin and beyond. *Econ. Lett.* 165, 58–61. <https://doi.org/10.1016/j.econlet.2018.02.001>
- Bundi, N., Wildi, M., 2019. Bitcoin and market-(in)efficiency: a systematic time series approach. *Digit. Finance* 1, 47–65. <https://doi.org/10.1007/s42521-019-00004-z>
- Choi, I., 1999. Testing the random walk hypothesis for real exchange rates. *J. Appl. Econom.* 14, 293–308. [https://doi.org/10.1002/\(SICI\)1099-1255\(199905/06\)14:3<293::AID-JAE503>3.0.CO;2-5](https://doi.org/10.1002/(SICI)1099-1255(199905/06)14:3<293::AID-JAE503>3.0.CO;2-5)
- Fama, E.F., 1970. Efficient Capital Markets: A Review of Theory and Empirical Work. *J. Finance* 25, 383. <https://doi.org/10.2307/2325486>

- Fidrmuc, J., Junge, F., Kapounek, S., 2020. Cryptocurrency Market Efficiency: Evidence from Wavelet Analysis. *Czech J. Econ. Finance* 70, 121–144.
<https://doi.org/10.32065/cjef.2020.02.02>
- Grobys, K., Sapkota, N., 2019. Cryptocurrencies and momentum. *Econ. Lett.* 180, 6–10.
<https://doi.org/10.1016/j.econlet.2019.03.028>
- Han, J.-B., Kim, S.-H., Jang, M.-H., Ri, K.-S., 2020. Using Genetic Algorithm and NARX Neural Network to Forecast Daily Bitcoin Price. *Comput. Econ.* 56, 337–353. <https://doi.org/10.1007/s10614-019-09928-5>
- Huang, J.-Z., Huang, W., Ni, J., 2019. Predicting bitcoin returns using high-dimensional technical indicators. *J. Finance Data Sci.* 5, 140–155.
<https://doi.org/10.1016/j.jfds.2018.10.001>
- Hurst, H.E. (1951). Long-Term Storage Capacity of Reservoirs. *Transactions of the American Society of Civil Engineers*, 116, 770-799.
- Jiang, Z., Liang, J., 2017. Cryptocurrency Portfolio Management with Deep Reinforcement Learning. *ArXiv161201277 Cs*.
- Kim, J.H., 2014. vrtest: Variance Ratio tests and other tests for Martingale Difference Hypothesis. CRAN. URL <https://cran.r-project.org/web/packages/vrtest/index.html>
- Kim, J.H., 2009. Automatic variance ratio test under conditional heteroskedasticity. *Finance Res. Lett.* 6, 179–185. <https://doi.org/10.1016/j.frl.2009.04.003>
- Kristoufek, L., 2015. What Are the Main Drivers of the Bitcoin Price? Evidence from Wavelet Coherence Analysis. *PLOS ONE* 10, e0123923.
<https://doi.org/10.1371/journal.pone.0123923>
- Lahmiri, S., Bekiros, S., 2019. Cryptocurrency forecasting with deep learning chaotic neural networks. *Chaos Solitons Fractals* 118, 35–40.
<https://doi.org/10.1016/j.chaos.2018.11.014>
- Ljung, G.M., Box, 1978. On a Measure of Lack of Fit in Time Series Models 8.
- López-Martín, C., Benito Muela, S., Arguedas, R., 2021. Efficiency in cryptocurrency markets: new evidence. *Eurasian Econ. Rev.* 11, 403–431.
<https://doi.org/10.1007/s40822-021-00182-5>
- Nadarajah, S., Chu, J., 2017. On the inefficiency of Bitcoin. *Econ. Lett.* 150, 6–9.
<https://doi.org/10.1016/j.econlet.2016.10.033>
- Nakamoto, S., 2008. Bitcoin: A Peer-to-Peer Electronic Cash System 11.

- Nakano, M., Takahashi, A., Takahashi, S., 2018. Bitcoin technical trading with artificial neural network. *Phys. Stat. Mech. Its Appl.* 510, 587–609.
<https://doi.org/10.1016/j.physa.2018.07.017>
- Sebastião, H., Godinho, P., 2021. Forecasting and trading cryptocurrencies with machine learning under changing market conditions. *Financ. Innov.* 7, 3.
<https://doi.org/10.1186/s40854-020-00217-x>
- Shintate, T., Pichl, L., 2019. Trend Prediction Classification for High Frequency Bitcoin Time Series with Deep Learning. *J. Risk Financ. Manag.* 12, 17.
<https://doi.org/10.3390/jrfm12010017>
- Silva de Souza, M.J., Almudhaf, F.W., Henrique, B.M., Silveira Negredo, A.B., Franco Ramos, D.G., Sobreiro, V.A., Kimura, H., 2019. Can artificial intelligence enhance the Bitcoin bonanza. *J. Finance Data Sci.* 5, 83–98.
<https://doi.org/10.1016/j.jfds.2019.01.002>
- Stöckl, S., 2022. crypto2: Download Crypto Currency Data from “CoinMarketCap” without “API.” CRAN. URL <https://CRAN.R-project.org/package=crypto2>
- Taleb, N.N., 2012. *Antifragile: things that gain from disorder*, 1st ed. ed. Random House, New York.
- Tran, V.L., Leirvik, T., 2020. Efficiency in the markets of crypto-currencies. *Finance Res. Lett.* 35, 101382. <https://doi.org/10.1016/j.frl.2019.101382>
- Tushar Chande, 1994, *The New Technical Trader*
- Urquhart, A., 2016. The inefficiency of Bitcoin. *Econ. Lett.* 148, 80–82.
<https://doi.org/10.1016/j.econlet.2016.09.019>
- Vidal-Tomás, D., 2022. Which cryptocurrency data sources should scholars use? *Int. Rev. Financ. Anal.* 81, 102061. <https://doi.org/10.1016/j.irfa.2022.102061>
- Wald, A., Wolfowitz, J., 1940. On a Test Whether Two Samples are from the Same Population. *Ann. Math. Stat.* 11, 147–162.
<https://doi.org/10.1214/aoms/1177731909>
- W. A. Brock, J. A. Scheinkman, W. D. Dechert & B. LeBaron (1996) A test for independence based on the correlation dimension, *Econometric Reviews*, 15:3, 197-235, DOI: 10.1080/074749396088003531994

Plagiatserklärung

„Ich bezeuge mit meiner Unterschrift, dass meine Angaben über die bei der Abfassung meiner Arbeit benützten Hilfsmittel sowie über die mir zuteil gewordene Hilfe in jeder Hinsicht der Wahrheit entsprechen und vollständig sind. Ich habe das Merkblatt zu Plagiat und Betrug vom 22.02.11 gelesen und bin mir der Konsequenzen eines solchen Handelns bewusst.“

Name, Vorname: Mazacek, Jonas

Ort und Datum: 17.06.2022, Basel

Unterschrift: _____